

Uso de Inteligência Computacional no Desenvolvimento de Fatiadores (Slicers) para Impressão 3D

Gustavo de Souza

Universidade do Estado de Santa Catarina (UDESC)

Departamento de Ciência da Computação

Joinville – SC – Brasil

gustavo.souza111@edu.udesc.br

José A. Laube

Universidade do Estado de Santa Catarina (UDESC)

Departamento de Ciência da Computação

Joinville – SC – Brasil

jose.laube17@edu.udesc.br

Abstract—A etapa de fatiamento (slicing) é um dos maiores pilares da manufatura aditiva, sua responsabilidade é traduzir geometrias tridimensionais em instruções de máquina (G-code). Tradicionalmente, esse processo depende de aproximações geométricas estáticas e heurísticas baseadas em tentativa e erro, o que limita a eficiência e a qualidade das peças. Este artigo apresenta uma revisão sistemática da literatura sobre a integração de técnicas de Inteligência Computacional no desenvolvimento e otimização de fatiadores. Encontra-se uma análise de como o Aprendizado de Máquina (Machine Learning), Redes Neurais Artificiais (ANNs), Aprendizado por Reforço (RL) e Algoritmos Evolutivos estão sendo empregados para resolver gargalos cruciais do fatiamento. Os resultados indicam que a inteligência artificial permite a otimização adaptativa da distância entre cordões (stepover), o controle dinâmico da dissipação térmica no planejamento de trajetórias (tool-path), e a criação de preenchimentos internos (infill) geometricamente eficientes, como o padrão lattice. Além disso, apresenta-se um estudo de caso do Neural Slicer, um fatiador autônomo baseado em redes neurais de otimizações aplicadas no mundo real. Assim, conclui-se que a transição de fatiadores com muita configuração e parametrização manual para sistemas preditivos e baseados em dados é um passo essencial para a consolidação da Manufatura Aditiva nos padrões da Indústria 4.0 no mundo todo, pois garante maior autonomia, resistência estrutural e economia de materiais e energia.

Index Terms—Manufatura Aditiva, Impressão 3D, Fatiadores (Slicers), Inteligência Computacional, Aprendizado de Máquina, Otimização de Trajetória.

I. INTRODUÇÃO

A manufatura aditiva, popularmente chamada de impressão 3D, teve um crescimento muito grande nas últimas décadas, consolidando-se como uma tecnologia importante no desenvolvimento de peças com geometria complexa, produtos personalizados e na redução de desperdício de materiais [1]. Diferentes dos processos subtrativos, a manufatura aditiva constrói camada por camada do objeto, isso permite que a fabricação de estruturas otimizadas e componentes com alto grau de complexidade, além de uma variedade de materiais.

Para fazer a transição de um modelo tridimensional digital para uma peça física impressa depende de uma etapa crítica, que é o processo de slicing (fatiamento). Esse processo é um software que vai converter o modelo 3D em instruções que a

impressora é capaz de entender. Nele são tomados decisões que vão impactar diretamente a qualidade da peça, o tempo da fabricação e o consumo de recursos, é no slicer que é configurado a altura das camadas de impressão, a orientação da peça, os suportes da estrutura e o planejamento da trajetória da impressora [2].

Os slicers operam por parâmetros definidos manualmente, o que exige conhecimento especializado e várias tentativas para acertar as configurações. Nesse contexto a inteligência computacional surge como uma abordagem promissora para superar as limitações dos fatiadores tradicionais. Técnicas de aprendizado de máquina têm mostrado uma capacidade relevante em conhecimento de padrões, otimização de parâmetros e no planejamento da trajetória [2]. Outros estudos usam de redes neurais para identificar características geométricas e determinar a altura das camadas, e planejamento adaptativo de caminhos [3].

O restante deste artigo está organizado da seguinte forma, na seção 2 são apresentados os fundamentos teóricos sobre o slicing e as principais técnicas de inteligência computacionais usadas nesse processo, na seção 3 é abordado a metodologia empregada neste trabalho, na seção 4 é discutidos os resultados, na seção 5 é abordado um estudo de caso e por fim na seção 6 fala das considerações finais.

II. FUNDAMENTAÇÃO TEÓRICA

A. O Processo de Slicing

Existem alguns métodos de manufatura aditiva, mas todos seguem um processo comum de etapas para criar um novo objeto [1]. A primeira etapa consiste na obtenção de um modelo CAD tridimensional, esse vai ser exportado para o software do slicer, geralmente usando o padrão STL (Standard Tessellation Language). O slicer realiza o fatiamento, convertendo o modelo 3D em finas camadas bidimensionais. Então um gerador de código G (linguagem compreendida pela impressora) cria um código que diz a trajetória da ferramenta em cada camada, essas etapas são feitas no mesmo software de fatiamento.

O processo de slicing envolve decisões que vão impactar diretamente no resultado final da peça, no tempo de fabricação e no consumo de recursos. Dentre os parâmetros a serem configurados então, altura da camada, camadas mais finas dão melhor precisão e acabamento mas aumentam o tempo de impressão, orientação da peça, determina a posição que a peça vai ser impressa, o que impacta na quantidade de suportes e pode comprometer a qualidade superficial e por fim o planejamento da trajetória, que vai definir o caminho que o bocal ou laser percorrerá para depositar o material.

B. Técnicas de Inteligência Computacional

A inteligência computacional, engloba o aprendizado de máquina (ML) e o aprendizado profundo (DL), e pesquisas atuais demonstraram que elas tem grande potencial de otimizar etapas do processo de slicing. Algumas das técnicas usadas para isso são, redes neurais artificiais (ANNs), as quais podem ser usadas para modelar a relação dos parâmetros de impressão e as propriedades finais da peça, as redes neurais convolucionais (CNNs) podem reconhecer características geométricas dos modelos 3D, assim identificando áreas que vão precisar de fatiamento adaptativo, já no aprendizado por reforço (RL), o agente pode aprender uma trajetória otimizada que reduz o tempo de impressão e por fim os algoritmos genéticos (GA), que podem ser utilizados para otimizar diversos objetivos conflitantes, como a precisão e o tempo de impressão.

III. METODOLOGIA

A metodologia adotada nesse trabalho para seguir o rigor científico e a reprodutibilidade é a de revisão sistemática da literatura. A busca por artigos foi feita nas bases de dados da Scopus, IEEE e Web of Science, reconhecidas por sua abrangência em literatura revisada por pares nas áreas de engenharia e ciência da computação. A busca foi feita sobre os seguintes termos: "additive manufacturing", "3D printing", "slicer", "adaptive slicing", "machine learning", "deep learning", "neural network", "reinforcement learning".

IV. RESULTADOS

A. Planejamento de Caminho Baseado em Redes Neurais para DED

Neste um estudo complementar, os pesquisadores investigaram como otimizar o planejamento de caminho para a tecnologia de deposição direta de energia (DED) com arco elétrico, utilizando uma rede neural feedforward (FNN) [4]. Mas antes de explicar o que eles fizeram, é importante entender alguns conceitos.

A DED (Direct Energy Deposition) é uma tecnologia de manufatura aditiva onde um material (geralmente na forma de pó ou arame) é depositado camada por camada através de um bocal aquecido por um laser, arco elétrico ou feixe de elétrons. No caso desse estudo, eles usaram o processo com arco elétrico, mais especificamente o GMAW (Gas Metal Arc Welding), que é um tipo de soldagem onde um arame metálico é derretido por um arco elétrico e depositado sobre a superfície.

Um dos grandes desafios nesse processo é determinar o *stepover* ideal, que nada mais é do que a distância entre os cordões de material depositados lado a lado. Se o *stepover* for muito grande, ficam vãos entre os cordões, comprometendo a qualidade da peça. Se for muito pequeno, o material se sobrepõe demais, gerando desperdício e irregularidades. O problema é que o *stepover* ideal depende de várias variáveis que interagem entre si de forma complicada, como a entrada de calor no material, a velocidade com que o arame é alimentado e a velocidade de deslocamento do bocal. Por causa disso, os métodos tradicionais ainda usam aproximações heurísticas (ou seja, "chutes" baseados em experiência) para definir esse parâmetro [4].

A proposta do estudo foi usar uma abordagem orientada por dados, ao invés de depender de fórmulas matemáticas fixas, eles treinaram uma rede neural feedforward (FNN), que é um tipo de rede neural onde as informações viajam apenas em uma direção, da entrada para a saída, sem ciclos de retroalimentação. Para isso, eles usaram uma combinação de dados reais de 16 ensaios de soldagem GMAW e dados artificiais gerados a partir de regressão linear múltipla e mapeamento estatístico. Isso é importante porque, muitas vezes, a quantidade de dados experimentais disponíveis é pouco, e os dados sintéticos ajudam a "ensinar" melhor a rede.

O modelo treinado foi integrado a uma interface gráfica simples (GUI), que permite ao operador inserir as velocidades de alimentação do arame e de deslocamento, e a rede já retorna o *stepover* ideal previsto. Isso torna o processo mais rápido e menos dependente da experiência do operador [4].

Os resultados mostraram que o método funciona bem para diferentes condições de entrada e consegue prever com confiabilidade perfis de cordão mais lisos e uniformes, melhorando a eficiência do processo tanto para manufatura aditiva quanto para aplicações de revestimento [4]. Na prática, isso significa que a qualidade da peça final melhora e o desperdício de material diminui.

Esse estudo é relevante para o desenvolvimento de *slicers* inteligentes porque mostra como redes neurais podem substituir modelos matemáticos estáticos por sistemas preditivos dinâmicos. Em vez de o *slicer* seguir sempre o mesmo padrão de caminho, ele poderia usar uma rede neural para ajustar o caminho de acordo com as características específicas de cada peça e cada processo, contribuindo para uma maior automação e eficiência [4].

B. Planejamento de Caminho Baseado em Aprendizado por Reforço para PBF

Em um estudo recente, pesquisadores propuseram uma abordagem inovadora para o planejamento adaptativo de caminho em fusão em leito de pó (PBF) utilizando aprendizado por reforço (RL) [5]. Antes de explicar a solução, é importante entender o contexto do problema e como o RL foi uma solução.

A PBF (Powder Bed Fusion) é uma tecnologia de manufatura aditiva onde uma fina camada de pó (metal, polímero ou cerâmica) é espalhada sobre uma plataforma e, em seguida,

uma fonte de energia, pode ser um laser ou feixe de elétrons, funde seletivamente as áreas correspondentes à seção diagonal da peça. Esse processo é repetido camada por camada até que o objeto esteja completo. É uma das tecnologias de AM mais utilizadas na indústria, especialmente para peças metálicas de alta precisão [5].

O problema central trago pelo estudo é que as estratégias convencionais de planejamento de caminho, como os padrões *zigzag* ou *raster*, ignoram a física do processo. Durante a impressão, a aplicação do laser gera gradientes térmicos complexos, ou seja, diferenças de temperatura significativas entre diferentes áreas da peça. Esses gradientes podem causar acúmulo de calor em algumas áreas, levando a defeitos como porosidade, empenamento ou falta de ligação entre camadas. Como os métodos tradicionais usam caminhos pré-definidos (que são basicamente "receitas" fixas), eles não conseguem se adaptar às condições térmicas que variam ao longo da impressão [5].

A solução proposta pelos pesquisadores foi usar RL, uma área da inteligência artificial onde um agente aprende a tomar decisões através da interação com um ambiente, recebendo recompensas ou penalidades conforme suas ações. O objetivo é que o agente aprenda a melhor política, ou seja, a melhor sequência de passos para maximizar a recompensa acumulada ao longo do tempo [5].

No estudo, o aprendizado foi feito junto com simulações térmicas por elementos finitos (FEA). A análise por elementos finitos é uma técnica computacional usada para simular o comportamento físico de materiais, como a distribuição de temperatura em uma peça durante o processo de impressão. Isso permitiu que os agentes aprendessem caminhos adaptativos a partir de informações detalhadas de temperatura medida em diferentes pontos da peça [5].

O treinamento foi realizado em ambientes mais simples geometricamente, mas com acoplamento térmico era realista, dessa forma o calor gerado em um ponto influencia os pontos vizinhos. Os pesquisadores também utilizaram uma técnica que cria automaticamente diferentes formas e padrões, para garantir que os agentes não se especializassem em apenas um tipo de geometria, mas conseguissem generalizar seu aprendizado para várias formas com irregularidade [5].

Os resultados obtidos foram bastante promissores. Os padrões aprendidos pelos agentes superaram as estratégias convencionais (como o *zigzag*) em termos de velocidade de impressão. Além disso, os agentes descobriram padrões emergentes que não eram esperados, como a estratégia de varredura de fora para dentro, onde o laser começa a fusão pelas bordas externas e vai em direção ao centro. Esse padrão ajuda a distribuir melhor o calor, evitando acúmulo em regiões específicas [5].

Este estudo é particularmente relevante para o desenvolvimento de *slicers* inteligentes porque mostra como agentes de RL podem aprender automaticamente estratégias de caminho que otimizam simultaneamente dois objetivos conflitantes, como a velocidade de impressão (tempo) e a qualidade da peça (distribuição térmica uniforme). Em vez de depender de

heurísticas fixas, um *slicer* baseado em RL poderia se adaptar em tempo real às condições do processo, ajustando o caminho conforme necessário para garantir a melhor qualidade possível [5].

C. Otimização de Preenchimento (Infill) com Redes Neurais Artificiais

A estrutura interna da peça é um fator crucial gerenciado pelo *slicer*, tão importante quanto o planejamento de trajetórias que foca na movimentação do cabeçote. O preenchimento interno de uma peça (*infill*) dita tanto o peso, como a resistência mecânica e a quantidade de material gasto. Os softwares *slicers* tradicionais oferecem padrões geométricos pré-definidos (como grade, ziguezague ou cúbico), mas eles não consideram a distribuição de forças que a peça sofrerá no mundo real, o que implica em peças que quebram ou racham com extrema facilidade.

Para solucionar essa ineficiência de impressão, Alejandrino et al. (2020) propuseram a introdução de um padrão de preenchimento tipo *lattice* (treliça), integrado a um algoritmo de Rede Neural Artificial (ANN), com o objetivo de aumentar a eficiência do material em impressões FDM sem perder resistência à compressão [6].

No estudo, a rede neural do tipo *feedforward* foi utilizada para realizar correções geométricas e lidar com os desvios de forma crucial para a impressão. As coordenadas 3D do padrão *lattice* foram extraídas como entradas para o modelo de ML, que foi treinado utilizando o algoritmo de gradiente conjugado escalonado (SCG). A saída da rede fornecia os parâmetros corrigidos para o arquivo STL, que então era fatiado no software Ultimaker Cura [6]. Os resultados demonstraram a capacidade dessa abordagem computacional, ao simular as tensões e deslocamentos, os pesquisadores comprovaram que o preenchimento *lattice* gerado com auxílio da IA suportava cargas de até 1.6 kN antes da ruptura, mas com uma economia de material impressionante de até 61,3% quando comparado aos padrões cúbicos tradicionais. Na prática, a aplicação de redes neurais no fatiador permitiu aumentar a produtividade de um único rolo de filamento em 2,5 vezes [6].

Entretanto, é evidente que isso teve um custo, que foi no tempo de impressão, nos testes relatados pelos autores o tempo de impressão de uma peça usando *lattice* foi o dobro quando comparado com um preenchimento tradicional, o que é um grande contraponto para o novo método de preenchimento pois tempo e energia são variáveis fundamentais na manufatura aditiva. Assim, o que pode-se concluir é que a aplicação de redes neurais para *infill* atualmente compensa majoritariamente em cenários onde o custo do material ou a necessidade de alívio de peso (como na indústria aeroespacial) justificam o aumento no tempo de máquina, pois o tempo e energia gastos são extremamente desfavoráveis para o uso de tal preenchimento a menos que haja de fato necessidade. Para o futuro, os *slicers* precisarão não apenas otimizar a geometria do preenchimento para resistir a varias aplicações de forças físicas sobre elas, mas também aplicar a IA para suavizar essas trajetórias internas no caso de preenchimentos complexos,

garantindo que a movimentação da impressora não seja um gargalo para o tempo de produção.

Porém, esse avanço demonstra que *slicers* do futuro não precisarão limitar o usuário a escolhas e configurações manuais e empíricas preenchimento e peça e setup de impressão. A inteligência computacional pode calcular o volume exato e a estrutura interna necessária baseando-se apenas na resistência exigida, gerando o G-code de forma autônoma, o que elimina de forma acentuada o erro humano e contribui para a maior acessibilidade e autonomia da manufatura aditiva no mercado de pesquisa e de grande público.

D. Geração de Estratégias de Sequência com Algoritmos Evolutivos

Outro desafio complexo no desenvolvimento de fatiadores, especialmente na manufatura aditiva de metais por Deposição Direta de Energia (DED), é o chamado Problema do Caminho da Ferramenta (*Tool-Path Problem*). Slicers comerciais frequentemente utilizam em suas gerações de trajetórias aproximações geométricas contínuas (como espirais ou contornos) que estão longe do ideal do ponto de vista de eficiência de tempo e dissipação térmica do metal [7].

Assim, Murua et al. (2020) modelaram esse desafio como um problema matemático de otimização multiobjetivo, denominado "Geração de Estratégia de Sequência". O objetivo do algoritmo não era apenas encontrar um caminho que cobrisse a peça, mas sim determinar a ordem exata na qual o cordão de solda deveria ser depositado para diminuir o tempo de inatividade da máquina e o tempo de espera para o resfriamento correto de cada camada [7], de forma que o desenvolvimento de novas confecções seja mais eficiente.

Porém, devido à alta complexidade computacional (similar ao clássico problema do Caixeiro Viajante), os métodos de análise dos autores falham. A solução encontrada foi a aplicação de Algoritmos Evolutivos (EAs), mais especificamente o NSGA-II (*Non-dominated Sorting Genetic Algorithm II*), uma técnica de inteligência computacional baseada em genética de populações [7].

O algoritmo genético recebeu um grafo representando as opções de adição de material da peça e começou a gerar permutações (rotas) que levam a construção bem sucedida da peça. Através de operadores de cruzamento (*crossover*) e mutação (*shuffle*), o algoritmo repetiu as gerações inúmeras vezes avaliando cada rota com base na distância percorrida pelo bico em vazio e no tempo de espera térmico medido por pirômetros.

Ao final do processamento, o algoritmo devolve um Conjunto de Pareto (soluções ótimas) em tempo acessível (cerca de 119 segundos), permitindo que o fatiador gere automaticamente o G-code mais eficiente possível para peças com dezenas de ramificações. Assim, a inserção de algoritmos evolutivos na etapa de fatiamento prova que o *slicer* pode ir além do planejamento espacial, integrando variáveis termodinâmicas e de tempo diretamente no cálculo da trajetória [7], o que muda totalmente o mercado da manufatura aditiva, onde os *slicers* param de ser tradutores de coordenadas e se

tornam capazes de modelarem fenômenos físicos complexos em tempo real e preverem desperdícios de movimentações assim como de materiais.

Uma reflexão necessária sobre esse estudo é a questão da escalabilidade computacional, pois o uso de Algoritmos Genéticos (NSGA-II) provou ser eficaz para encontrar a rota ideal em peças com dezenas de ramificações, o que retorna um conjunto de Pareto em poucos minutos. Porém, em confecções industriais de grande porte, que dependendo da sua modelagem podem gerar milhões de componentes interligados, o custo computacional de um algoritmo evolutivo que o resolve (encontra rota ideal) pode crescer exponencialmente. Isso levanta um ponto importante de se questionar que seria até que ponto é viável transferir o poder de processamento do fatiamento para um processador na nuvem (*Cloud Slicing*)? Pois se os fatiadores do futuro exigirem o processamento de algoritmos genéticos pesados a cada nova peça, essa elevada adaptação e não repetibilidade exigirá muito recurso local para as máquinas, os computadores dos usuários dessas empresas possivelmente não serão suficientes um dia. Assim, pode-se imaginar que a evolução dos fatiadores inteligentes poderá depender diretamente da capacidade de processamento distribuído, permitindo assim uma elasticidade vertical no sistema de modelagem e confecção de produtos e melhorando o desenvolvimento de inovações nas próximas décadas.

V. ESTUDO DE CASO

Como forma de mostrar uma aplicação prática da inteligência computacional no desenvolvimento de *slicers*, este estudo analisou o artigo "Neural Slicer", proposto por Liu et al. (2024). O trabalho consiste no fatiamento para impressão 3D multi-eixos, onde o objetivo é gerar camadas curvas que eliminem a necessidade de suportes e aumentem a resistência do objeto final.

O problema que o artigo observou foi que *slicers* tradicionais frequentemente falham com modelos que têm uma estrutura topológica complexa ou dependem de uma representação do objeto com uma malha de alta qualidade, o que demanda muito processamento. Além disso, métodos anteriores como o S3-Slicer otimizavam os objetivos de manufatura no espaço deformado, o que poderia gerar distorções ao mapear as camadas de volta para o espaço do modelo. O Neural Slicer tenta resolver esses problemas formulando o fatiamento como uma tarefa de otimização diretamente no espaço original do modelo.

O Neural Slicer utiliza uma malha volumétrica de encapsulamento (*caging mesh*) C como representação intermediária, independente da representação discreta do modelo de entrada [8]. O mapeamento $\lambda : \mathbf{x} \mapsto \mathbf{y}$ é parametrizado por duas funções contínuas representadas por redes neurais.

- $q(\mathbf{x})$ – função que define a rotação local em cada ponto;
- $s(\mathbf{x})$ – função que define as razões de escala local.

O fatiador vai implementar uma rede neural, a configuração utilizada é de 10 camadas ocultas e 512 neurônios em cada camada. Essa rede vai ser responsável por aprender as funções $q(\mathbf{x})$ e $s(\mathbf{x})$, e com o uso de ativações senoidais (SIREN) vai

permitir que a rede reconheça detalhes geométricos complexos e pequenas variações nas direções de impressão (LPDs), que são definidos a partir do gradiente do campo escalar $G(x)$.

O que o estudo faz diferente dos algoritmos de controle lógico tradicionais, é utilizar o otimizador Adam para minimizar uma função de perda multi-objetivo (L). Esta função vai considerar diferentes objetivos como, Lsf que garante o ângulo de deposição vai respeitar os limites de auto-suporte da peça, Lsr que respeita o alinhamento das camadas com as direções da tensão principal e Lca que impede que o cabeçote de impressão colida com a peça.

Para a avaliação do modelo, o estudo validou os resultados com um objeto de alta complexidade, no caso foi uma cabeça de coelho em um sistema robótico com 6 graus de liberdade. Foi observado que, enquanto métodos clássicos falham se o modelo não estiver bem orientado, a rede neural conseguiu convergir para soluções ótimas partindo de diferentes estados iniciais. Isso demonstra uma estabilidade maior no sistema de fatiamento. Os histogramas apresentados no artigo mostram que mais de 95% das LPDs nos modelos testados atendem aos requisitos de autossuporte e alinhamento com as tensões principais.

Nos testes de flexão para analisar a resistência da peça, o fatiamento do Neural Slicer reduziu a deformação máxima em 40,5% em comparação com o S3-Slicer, além de dobrar a força de ruptura em testes de flexão de 3 pontos [8]. Quanto ao tempo de processamento, o fatiador foi capaz de gerar camadas curvas para modelos com milhões de faces em menos de 15 minutos, o que o coloca em um tempo competitivo em relação a outros fatiadores disponíveis no mercado.

Com este trabalho, foi possível entender que integrar redes neurais no fatiador transforma o processo da manufatura aditiva de uma sequência de comandos estáticos em um sistema de otimização dinâmica. Além da capacidade de autogestão das direções de impressão, minimizando caminhos e evitando colisões por meio do aprendizado de máquina, essa abordagem reduz a intervenção humana na preparação do código que a impressora irá executar. Isso está muito alinhado com as propostas da Indústria 4.0, onde sistemas autônomos e adaptáveis são cada vez mais valorizados.

VI. CONCLUSÕES

Este trabalho apresentou uma revisão aprofundada sobre como a inteligência computacional está revolucionando a manufatura aditiva, com foco especial no desenvolvimento de softwares fatiadores (*slicers*). Desde sempre a etapa de fatiamento dependeu muito do método de tentativa e erro e da intuição do operador para configurar os parâmetros e efetuar uma boa confecção. Porém, a análise da literatura recente deixou claro que esse modelo puramente manual, geométrico e rudimentar está ultrapassado diante das necessidades do mundo atual.

Ficou evidente que diferentes técnicas de Inteligência Artificial conseguem resolver gargalos bastante específicos do processo de impressão 3D e de confecções complexas. As Redes Neurais Artificiais (ANNs e FNNs), por exemplo, provaram

ser ferramentas excelentes tanto para prever parâmetros de solda em impressão de metais (como o *stepover*), quanto para gerar padrões de preenchimento (*infill*) usando o formato *lattice*. Isso permitiu criar peças muito mais resistentes gastando consideravelmente menos material, o que é de extrema importância para a indústria. Por outro lado, técnicas como Algoritmos Evolutivos e Aprendizado por Reforço (RL) mudaram a forma como o bico da impressora se movimenta, em vez de executar um caminho em ziguezague, o *slicer* inteligente passa a considerar a física do processo, como o calor, gerando trajetórias (*tool-paths*) que evitam falhas e deformações térmicas e economizando muito dinheiro com possíveis falhas futuras durante a operação já do produto.

O estudo de caso do *Neural Slicer* reforçou esses achados, pois nela há uma clara demonstração do estado da arte da área. O fato de um software conseguir fatiar modelos de altíssima complexidade diretamente no espaço vetorial, eliminando suportes desnecessários e alinhando as camadas com as linhas de tensão da peça, mostra um nível de autonomia enorme. Na prática, isso ataca um dos maiores desafios de quem trabalha com itens produzidos de manufatura aditiva: a perda de peças e tempo por falhas no arquivo fatiado gerado. Em suma, a integração de *Machine Learning* no desenvolvimento de fatiadores não é apenas uma atualização de software ou um fluxo da onda moderna de inovações tecnológicas onde o termo "IA" tornou-se marketing para chamar atenção do grande público, mas sim um passo obrigatório para alinhar a manufatura aditiva aos padrões da Indústria 4.0 que já está em andamento. Como trabalhos futuros, a grande expectativa é que essas abordagens baseadas em dados e algoritmos genéticos, hoje focadas em laboratórios de pesquisa de universidades ao redor do mundo, comecem a ser implementadas nativamente nos *slicers* comerciais, sejam privados ou de código aberto, pois assim o futuro da manufatura aditiva garante uma constante renovação e atualização aos padrões de mercado, o qual exige sistemas que não apenas traduzam a geometria tridimensional para a máquina, mas que prevejam, aprendam e otimizem toda a fabricação antes mesmo da primeira camada de material ser depositada na mesa de criação.

REFERENCES

- [1] Y. Wang, P. Zheng, T. Peng, H. Yang, and J. Zou, "Smart additive manufacturing: Current artificial intelligence-enabled methods and future perspectives," *Science China Technological Sciences*, vol. 63, pp. 1600–1611, 2020.
- [2] F. Ciccone, A. Bacciaglia, and A. Ceruti, "Optimization with artificial intelligence in additive manufacturing: a systematic review," *Journal of the Brazilian Society of Mechanical Sciences and Engineering*, vol. 45, no. 303, 2023.
- [3] Z. Zhu, K. Ferreira, N. Anwer, L. Mathieu, K. Guo, and L. Qiao, "Convolutional neural network for geometric deviation prediction in additive manufacturing," *Procedia CIRP*, vol. 91, pp. 534–539, 2020.
- [4] K. C. Riffel, R. Bawa, J. Chan, R. Adhami, D. Gofman, and A. J. Ramirez, "Artificial intelligence and statistical mapping applied to additive manufacturing toolpath optimization in wire-arc ded," *Integrating Materials and Manufacturing Innovation*, 2025.
- [5] R. Schmeitz, R. J. M. Wolfs, and J. J. C. Remmers, "Learning-based toolpath planning for bed-based additive manufacturing," *Engineering with Computers*, vol. 42, no. 101, 2026.

- [6] J. D. Alejandrino, R. S. C. II, S. C. Lauguico, R. R. Tobias, L. Venancio, D. Macasaet, A. A. Bandala, and E. P. Dadios, "A machine learning approach of lattice infill pattern for increasing material efficiency in additive manufacturing processes," *International Journal of Mechanical Engineering and Robotics Research*, vol. 9, no. 9, pp. 1253–1263, 2020.
- [7] M. Murua, A. Suárez, D. Galar, and R. Santana, "Tool-path problem in direct energy deposition metal-additive manufacturing: Sequence strategy generation," *IEEE Access*, vol. 8, pp. 91 574–91 585, 2020.
- [8] T. Liu, T. Zhang, Y. Chen, Y. Huang, and C. C. L. Wang, "Neural slicer for multi-axis 3d printing," *ACM Transactions on Graphics*, vol. 43, no. 4, pp. 1–15, 2024.