

Inteligência Artificial

Aprendizado de Máquina

Prof. Rafael Stubs Parpinelli

DCC / UDESC-Joinville

rafael.parpinelli@udesc.br



O que é Aprendizado de Máquina? (*Machine Learning* - ML)

- Realiza análise de dados que automatiza a construção de modelos analíticos.
- É um ramo da inteligência artificial baseado na ideia de que sistemas podem aprender com dados, identificar padrões e tomar decisões com o mínimo de intervenção humana.
 - **Aprender** significa “**mudar para fazer melhor**” (de acordo com um dado critério) quando uma situação similar acontecer.
 - Aprendizagem, **não é memorizar**. Qualquer computador pode memorizar, a dificuldade está em **generalizar** um comportamento para uma nova situação.


Inteligência Artificial e Aprendizado de Máquina

The Difference Between Artificial Intelligence and Machine Learning


<https://youtu.be/ihd9zrW6DOK>


Machine Learning and AI

<https://youtu.be/4qKtQD5133k>



ML Workflow






Formas de Aprendizado


- Aprendizado Supervisionado

- a máquina é treinada através de um conjunto de dados onde para cada entrada a saída é conhecida
 - Regressão, classificação
- Aprendizado Semi-Supervisionado



- Aprendizado Não Supervisionado

- os dados não possuem rótulo, ou seja, a saída correta não é informada
 - Agrupamento, associação




Objetivo: Agrupar objetos semelhantes

- Aprendizado por Reforço

- a máquina faz uma hipótese determina se esta hipótese é boa ou ruim com base em recompensas ou punições das ações

Informação de Treinamento = Avaliação (Recompensas, Punições)



Objetivo: Conseguir o máximo de reforço possível

Alguns Algoritmos

- **Aprendizado Supervisionado**

- Naive Bayes
- Árvores de Decisão
- Random Forests
- Linear / logistic regression
- k-NN
- SVM
- Redes Neurais:
 - ANN: regressão e classificação
 - CNN: classificação em visão computacional
 - RNN: Análise de séries temporais
- Algoritmos Evolutivos

- **Aprendizado Não Supervisionado**

- Clusterização Sequencial
- Clusterização Hierárquica
- K-Means
- Redes Neurais:
 - Mapas auto-organizáveis (SOM): Detecção de características e Agrupamento
 - Boltzman Machines: Sistemas de recomendação
- Algoritmos Evolutivos


- **Aprendizado Por Reforço**

- Q-learning
- Redes Neurais: Deep Q-learning


<https://machinelearningmastery.com/a-tour-of-machine-learning-algorithms/>

Aprendizado Supervisionado

- Necessita de dados rotulados
- Faz uma predição a partir de exemplos
- Tipos de tarefas/problemas
 - **Regressão:**
 - Predizer o valor da bolsa amanhã, dados os valores de dias e meses anteriores.
 - **Classificação:** Responde se uma determinada “entrada” pertence a uma certa classe.
 - Dada a imagem de um objeto: qual objeto é este, dentre um número finito de objetos?



Regressão



Algoritmos de regressão são usados quando a saída desejada (atributo meta ou *label*) é contínua. Ou seja, a saída da pergunta de classificação recai em um valor de quantidade que pode ser determinada baseada nas entradas do modelo.

Dada um conjunto de dados para o treinamento, temos que derivar uma função h que se aproxime da verdadeira função $f(x)$ (a qual gerou os dados e é desconhecida).

Existe um número infinito de funções h .








Ilustração de *Under* e *Overfitting*


Regression




Classificação




Deep Learning Algorithms



Bayesian Algorithms



Decision Tree Algorithms



Instance-based Algorithms

Possui um conjunto de variáveis independentes (atributos previsores) que atribuem uma classe para uma variável dependente (atributo meta ou *label*).


Algoritmos de classificação são usados quando a saída desejada (atributo meta ou *label*) é discreta ou categórica. Ou seja, a saída da pergunta de classificação recai sobre um conjunto finito de possibilidades.

Atributos							Classe
Exemplo	Atrib ₁	Atrib ₂	Atrib ₃	Atrib ₄	Atrib ₅	Atrib ₆	
X ₁	0.24829	0.49713	0.00692	-0.020360	0.429731	-0.2935	1
X ₂	0.24816	0.49729	0.00672	0.0065762	0.431444	-0.29384	1
X ₃	0.24884	0.49924	0.01047	-0.002901	0.423145	-0.28956	3
X ₄	0.24802	0.50013	0.01172	0.001992	0.422416	-0.29092	2
X ₅	0.24775	0.49343	0.01729	-0.014341	0.420937	-0.29244	2


Atributos							Classe
Exemplo	Atrib ₁	Atrib ₂	Atrib ₃	Atrib ₄	Atrib ₅	Atrib ₆	
X ₁	0.22829	0.48713	0.00592	-0.010360	0.419731	-0.2845	?
X ₂	0.21816	0.48729	0.00572	0.0045762	0.421444	-0.28484	?
X ₃	0.23884	0.49824	0.01447	-0.003901	0.433145	-0.24956	?
X ₄	0.23002	0.49013	0.02172	0.002992	0.412416	-0.28092	?
X ₅	0.24575	0.49243	0.01029	-0.015341	0.430937	-0.28244	?

Ilustração de *Under* e *Overfitting*


Classification



Underfitting



Just Right




Overfitting

Fases da Aprendizagem


- **Treinamento**
 - Apresenta-se exemplos ao sistema.
 - O sistema “aprende” a partir dos exemplos.
 - O sistema modifica gradualmente os seus parâmetros para que a saída se aproxime da saída desejada ou maximize sua métrica de desempenho.
- **Teste**
 - Novos exemplos jamais visto são apresentados ao sistema.
 - O sistema deve generalizar e reconhecê-los.

Modelagem Supervisionado


Passo 1: Separar os dados



Passo 2: Treinar o modelo




Passo 3: Avaliar o modelo



Modelagem Supervisionado

Dois estágios para geração do modelo:

1. Modelo ajustado (tuning)
2. Teste




Avaliação dos modelos

O desempenho do modelo pode depender de outros fatores além do algoritmo de aprendizado

- Distribuição de classes
- Custo de uma classificação errada
- Tamanho dos conjuntos de treinamento e test

Avaliação dos modelos

- Holdout
 - 2/3 para treinamento e 1/3 para teste
- Random Subsampling
 - Porções definidas aleatoriamente e realizadas várias vezes
- Cross Validation
 - Os dados são divididos em **k** partições mutuamente excludentes, **folds**, de mesmo tamanho
 - Cada subconjunto é utilizado uma vez para teste e os demais par treinamento
- Leave-one-out Cross Validation
 - Usa **k** igual ao número de casos observados na base



Underfitting e Overfitting


Sub-ajuste e Sobreajuste

- *Underfitting*: o modelo não captura a tendência subjacente dos dados.
- *Overfitting*: o modelo captura o ruído dos dados.

Performance on ...	Underfitting	Overfitting
Training set	Bad	Good
Testing set	Bad	Bad

Bias-variance tradeoff

- Diagrama **Bulls-eye**
 - O **centro do alvo** representam modelos que predizem perfeitamente os valores corretos dos dados. Ao se afastar do centro do alvo, a predição vai ficando cada vez pior.
 - **Cada ponto** representa a assertividade de um modelo construído. Sendo assim, múltiplos pontos indicam que o processo de construção e avaliação do modelo de predição foi realizado múltiplas vezes.
- **Bias** diz respeito a tendência do modelo em prever erroneamente. O erro por bias é obtido pela diferença (ou média) entre o valor predito pelos modelos e o valor correto da predição.
- **Variância** diz respeito ao quão espalhados estão os resultados obtidos por múltiplos modelos. O erro por variância é obtido pela variabilidade dos valores dos múltiplos modelos.
- Idealmente, o modelo de aprendizado deve:
 - Capturar com precisão as regularidades dos dados de treinamento e também generalizar bem nos dados de teste
 - Infelizmente, o desafio é ter um modelo com um bom **tradeoff de resultados entre bias e variância**
- Idealmente, deseja-se que o modelo tenha **baixa variância e baixo bias** nos casos de teste.




Bias-variance tradeoff


Entendendo Over- e Under-fitting

- **Underfitting:** o modelo não captura a tendência subjacente dos dados. **Baixa variância e alto bias.**
- **Overfitting:** o modelo captura o ruído dos dados. **Alta variância e baixo bias.**

Performance on ...	Underfitting	Overfitting
Training set	Bad	Good
Testing set	Bad	Bad



OVERFIT VS UNDERFIT



Ideal

Over


Low Variance

High Variance

Low Bias

High Bias

Under



Métricas

Existe algumas métricas que podem ser utilizadas para ter uma medida que fale a quantidade de acertos, erros ou o desempenho da técnica utilizada. Algumas métricas interessantes serão descritas logo abaixo:



Acurácia: essa métrica é a mais básica para medir o aprendizado, leva em consideração a proporção de predições corretas, sem levar em consideração a quantidade de erros.

Sensibilidade: é a proporção de verdadeiros positivos, ou seja, a capacidade do algoritmo em prever casos corretamente para os casos que são realmente verdadeiros.


Especificidade: A proporção de verdadeiros negativos: a capacidade do algoritmo em predizer situações erradas que realmente são falsas.

Eficiência: é a média aritmética da sensibilidade e especificidade. Indica se o algoritmo está mais suscetível a ter verdadeiros positivos ou verdadeiros negativos.

Aprendizado Não-Supervisionado



- O principal interesse do aprendizado não-supervisionado é desvendar a organização dos padrões (similaridades e diferenças) existentes nos dados através de *clusters* (agrupamentos) consistentes
- Tipos de tarefas/problemas
 - **Agrupamento**: processo de agrupar um conjunto de objetos físicos ou abstratos com características similares
 - **Redução de Dimensionalidade**



Aprendizado Por Reforço

- É uma área de Aprendizado de Máquina preocupada com a forma como os agentes de software devem tomar ações em algum ambiente para maximizar alguma noção de recompensa cumulativa.
- Não existem conjuntos de dados rotulados ou não rotulados. Aprendizado se dá pela experiência.

