

# Inteligência Artificial

Redes Neurais Artificiais






# Conteúdo

- Introdução às Redes Neurais Artificiais
- Pré Processamento de Dados




**A conexão de neurônios biológicos têm uma grande capacidade de processar informações complexas**




# Neurônio

Neuron



- As três partes do neurônio: dendritos, o axônio e núcleo celular
- Os detritos são responsáveis por receber as entradas de outros neurônios, e os axônios são responsáveis por transmitir a saída
- Um neurônio está conectado a outro neurônio e a comunicação é feita mediante sinapses
- Os neurotransmissores podem ter efeito excitatório ou inibitório nos neurônios vizinho


# Neurônio Artificial



- Estrutura matemática proposta por McCulloch e Pitts em 1943.
- É ativado quando a combinação linear de suas entradas excedam algum limiar.
- A conexão dos neurônios artificiais é feita por meio de ligações, cada ligação possui um peso numérico

# LIGAÇÕES DE ENTRADA


As entradas são somadas sendo elas multiplicadas pelos pesos de cada ligação



$$\sum_{i=0}^{i=n} X_i * W_i$$

# BIAS


O bias é um parâmetro que adiciona uma constante. É usado para ajustar a saída da função de ativação. Sem ele podemos ficar restritos a soluções limitadas;



$$\sum_{i=0}^n x_i * w_i + B$$

# FUNÇÃO DE ATIVAÇÃO

Responsável por introduzir não-linearidades nos neurônios, permitindo que a rede aprenda e modele relações complexas nos dados.




$$F\left(\sum_{i=0}^{i=n} x_i * w_i + B\right)$$

# Tanh

Capacidade de mapear valores reais para o intervalo  $[-1, 1]$ . Ela é particularmente útil em problemas de classificação e regressão onde os dados estão centrados em torno de zero.

# Sigmóide

Ela mapeia qualquer valor real para o intervalo  $(0, 1)$ , tornando-a ideal para problemas de classificação binária, onde a saída desejada é uma probabilidade.





# Linear

Função de ativação linear é uma das mais simples, retornando o próprio valor de entrada como saída. É comumente usada na camada de saída de modelos de regressão, onde a previsão é uma combinação linear dos recursos de entrada.

# Relu


Retorna 0 para valores negativos e o próprio valor para valores positivos. Pode "apagar" alguns neurônios durante o treinamento, aumentando a velocidade, mas também pode levar à "morte" de neurônios se receberem apenas valores negativos.





# Conectando os Neurônios


- Cada neurônio artificial é um nó.
- As conexões são as arestas, e possuem pesos
- Os neurônios podem ser conectados de forma acíclica e cíclica (RECORRENTES)
- Podem ser totalmente conectados ou parcialmente.
- Existem 3 tipos de camadas: Entradas, Ocultas e Saída.



# Camadas

## Camada de Entrada


- Esta é a primeira camada da rede neural, onde os dados de entrada são introduzidos.
- Cada neurônio nesta camada representa uma característica ou atributo dos dados de entrada.
- O papel desta camada é receber os dados brutos e transmiti-los para as camadas ocultas para processamento.



# Camadas

## Camadas de Ocultas


- Ocorre o processamento principal da rede neural.
- recebem entradas das camadas anteriores e produzem saídas que servem como entradas para as camadas seguintes.
- O papel das camadas ocultas é extrair características e padrões complexos dos dados de entrada.





# Camadas

## Camadas de Saída



- Esta é a última camada da rede neural, onde as saídas finais da rede são geradas.
- Cada neurônio nesta camada representa uma classe, valor ou categoria que a rede está tentando prever ou classificar.
- O papel desta camada é produzir as previsões ou classificações finais



# Regressão




# Classificação



# Arquiteturas

## Perception


- Elas consistem em uma única camada de neurônios, sem camadas ocultas, conectados diretamente à camada de saída.
- Cada neurônio nesta camada representa uma classe, valor ou categoria que a rede está tentando prever ou classificar.
- O papel desta camada é produzir as previsões ou classificações finais




# Arquiteturas


## Multicamadas

- As arquiteturas multicamadas possuem uma ou mais camadas intermediárias antes da camada de saída, essas camadas também são chamadas de camadas ocultas.
- O modelo mais comum é o totalmente conectado onde todos os neurônios de uma camada  $l$  estão conectados a todos os neurônios de uma camada  $l+1$





Totalmente Conectada





Parcialmente Conectada

# Arquiteturas

## Recorrente

- Possuem nós que conectam a saída com a entrada, pode ser modificada dependendo o conjunto de dados de entrada,
- Podendo dizer que as RNA recorrentes possuem memórias,
- Projetado para lidar com dados sequenciais, onde a ordem e a interdependência dos dados são importantes.






**Como uma rede neural funciona?**

Área

Banheiros

Distância da Cidade

Idade




Área

Banheiros

Distância da Cidade

Idade



**Como uma rede neural aprende?**

# Aprendizado do Modelo


## Ajustes dos Pesos


### Aprendizado

O processo de aprendizado de uma rede se dá primeiramente com pesos iniciais, o ajuste desse peso vai sendo feito a partir das predições, se a predição for diferente do que se esperava os pesos são ajustado

# Aprendizado

- Atualiza os pesos com base no erro do modelo.  
Busca minimizar os erros.
- Cálculo mais simples do erro:
  - $Y - \hat{Y}$
- Atualiza o peso.






Entrada  
(Features)

| Horas de Estudo | Horas de Sono | Nota Semestre | Exame |
|-----------------|---------------|---------------|-------|
| 12              | 6             | 68            | 93    |
| 22              | 6.5           | 67            | 68    |
| 31              | 9             | 24            | 80    |

93  
Saída Esperada


Saída




| Horas de Estudo | Horas de Sono | Nota Semestre | Exame |
|-----------------|---------------|---------------|-------|
| 12              | 6             | 68            | 94    |
| 22              | 6.5           | 67            | 68    |
| 31              | 9             | 54            | 80    |

$$\text{Peso(novo)} = \text{peso(n)} * \text{taxa de aprendizagem} * \text{entrada} * \text{erro}$$


$$\text{Peso(novo)} = \text{peso(n)} * 0.03 * \text{entrada} * \text{erro}$$





| Horas de Estudo | Horas de Sono | Nota Semestre | Exame |
|-----------------|---------------|---------------|-------|
| 12              | 6             | 68            | 94    |
| 22              | 6.5           | 67            | 68    |
| 31              | 9             | 54            | 80    |

$$\text{Peso(novo)} = \text{peso(n)} * \text{taxa de aprendizagem} * \text{entrada} * \text{erro}$$



# Vantagens

## Capacidade de Aprender

As redes neurais capturam relações complexas nos dados, adaptando-se a características intrínsecas dos dados de entrada.

## Capacidade de Generalizar

Capacidade em identificar padrões e relações nos dados de treinamento e aplicá-los de forma eficaz a novos cenários.

## Tolerância a Falhas e Ruídos

Devido à sua arquitetura distribuída e à capacidade de aprender representações de alto nível dos dados, tendem a ser robustas em relação a ruídos e erros nos dados de entrada.

## Automação e Eficiência

Sua capacidade de aprendizado contínuo também permite que se adaptem a mudanças nas condições do ambiente ao longo do tempo.

# Desvantagens

## Requisitos Computacionais Elevados.

Treinar redes neurais pode demandar grande poder computacional.

## Dependência de Dados de Treinamento


Depende da qualidade e representatividade dos dados de treinamento disponíveis.

## Suscetibilidade a Overfitting

Podem se ajustar demais aos dados de treinamento, resultando em baixo desempenho em dados não vistos se não forem adequadamente regularizadas.

## Ajuste Hiperparâmetros

Treinar e otimizar redes neurais pode ser uma tarefa complexa, exigindo experiência e ajuste cuidadoso de hiperparâmetros.



# Tarefa

Utilizar o Playground do TensorFlow

[playground.tensorflow.org](https://playground.tensorflow.org)

# Análise Exploratória



# Análise Exploratória de Dados

## O que é?




A análise exploratória de dados é uma abordagem para analisar, resumir e visualizar dados para extrair insights e detectar padrões, tendências e relações entre variáveis.

## Por que fazer?

Identificação de padrões. Detecção de outliers. Formulação de hipóteses. Preparação de dados.



# Análise de Distribuição de Dados

- Gráficos para analisar a distribuição de dados.



# Análise de Correlação

- Coeficiente de correlação entre cada par de variáveis em um conjunto de dados



# Pré - Processamento



# Pré-processamento dos Dados

## O que é?

Refere-se ao conjunto de técnicas utilizadas para preparar e limpar os dados antes de serem alimentados na RNA. Também pode estar relacionado a criação, transformação ou seleção de variáveis a partir das variáveis originais do conjunto de dados.

## Por que fazer?

Melhora a eficácia e eficiência do treinamento da RNA, permitindo que o modelo aprenda padrões relevantes nos dados de forma mais precisa e rápida. Além disso, alguns tipos de dados podem não ser adequados para serem processados.

# Dados Duplicados

- Uma abordagem é remover as duplicatas, mantendo apenas uma instância de cada entrada repetida.

| ID | CPF            | Salario | Formação | Cidade    |
|----|----------------|---------|----------|-----------|
| 01 | 021.012.012.03 | 1.500   | 1        | Joinville |
| 02 | 784.152.124.12 | 3.500   | 1        | Vitoria   |
| 03 | 784.152.124.12 | 3.500   | 2        | Vitoria   |
| 04 | 028.245.001.02 | 6.600   | 3        | São Paulo |

# Dados Ausentes

- Atribuir um novo rótulo (categóricos).
- Atribuir rótulo com base na média (numéricos).
- Remover as observações com valores ausentes
- Exclusão da variável

| ID | CPF            | Salário | Formação | Cidade        |
|----|----------------|---------|----------|---------------|
| 01 | 021.012.012.03 | 1.500   | 1        | Joinville     |
| 02 | 784.152.124.12 | 3.500   | 1        | Vitória       |
| 03 | 478.521.697.14 | 3.500   |          | Ouro Preto    |
| 04 | 028.245.001.02 | 6.600   | 3        | São Paulo     |
| 05 | 089.542.268.21 |         | 2        | Fortaleza     |
| 06 | 047.269.315.24 | 9.600   |          | Florianópolis |
| 07 | 014.246.015.03 |         | 3        |               |

# Padronização de dados.


- Estabelecer categorias fechadas.
- Processamento de linguagem natural.
- Equivalências para categorias abertas.
- Validar dados para garantir lógica.

| Cidade    |
|-----------|
| Joinville |
| vitória   |
| joinnvile |
| São Paulo |
| SP        |
| VITORIA   |
| joinville |

| Cidade    |
|-----------|
| Joinville |
| Vitória   |
| Joinville |
| São Paulo |
| São Paulo |
| Vitória   |
| Joinville |

# Normalização de dados.

A normalização de uma variável visa ajustar sua distribuição para se assemelhar mais a uma distribuição normal, tornando as análises estatísticas mais robustas e confiáveis.



# One-Hot encoding


- Usado para lidar com variáveis categóricas
- Cada categoria única é transformada em uma nova variável binária.
- Evita a introdução de uma hierarquia incorreta entre as categorias.

| Cargo      | Cargo |
|------------|-------|
| Gerente    | 1     |
| Assistente | 2     |
| Gerente    | 1     |
| Assistente | 2     |
| Técnico    | 3     |

| Gerente | Assistente | Técnico |
|---------|------------|---------|
| 0       | 1          | 0       |
| 1       | 0          | 0       |

# Tratando Outliers

- Ponto de dados que se afasta significativamente do restante dos dados em um conjunto.
- Podem afetar a média e o desvio padrão, e introduzir viés nos coeficientes dos modelos.
- Remover os outliers do conjunto de dados.
- Transformar os valores dos outliers para torná-los menos influentes.



# Engenharia de Atributos

Processo de criar e selecionar características relevantes a partir dos dados brutos

- Selecionar atributos relevantes.
- Criar novos atributos a partir de atributos existentes.


| Área Interna | Área Externa | Área Total |
|--------------|--------------|------------|
| 105          | 20           | 125        |
| 482          | 100          | 528        |
| 40           | 12           | 52         |
| 100          | 50           | 150        |



# Tarefa

Aplicar Pré-Processamento em uma base de dados

## PROCESSO DE APLICAÇÃO DE MACHINE LEARNING



# Duvidas?

[gomesfmaisa@gmail.com](mailto:gomesfmaisa@gmail.com)

