

Aula 3

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 17 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA


LABICOM
Laboratório de Pesquisa
em Inteligência Computacional

Sumário

- Recapitulação das últimas aulas
 - Tokenização
 - Embeddings
- Introdução ao mecanismo de atenção
 - Simplificação
 - Mecanismo completo


Arquitetura GPT-2

Aula de hoje: Camada de atenção



Recapitulação

- O nosso objetivo é construir um modelo generativo, ou seja, que gere texto novo
- No caso dos chatbots, queremos uma conversa entre sistema e usuário
- Ou seja, iniciamos com um texto de entrada e desejamos um texto de saída (com base na entrada)



Recapitulação

- Para isso, primeiro separamos o texto de entrada em partes menores, chamadas de tokens

A rápida raposa marrom pula
sobre o cachorro preguiçoso




A rápida raposa marrom pula sobre
o cachorro preguiçoso

- Por que separar o texto em partes menores?
- Por que em tokens?

Recapitulação

- Em seguida, transformamos cada token em um vetor multidimensional



- Por que converter em vetores multidimensionais?

(DESAGULIER, 2018)

Recapitulação

- E agregamos a posição de cada token em sua representação multidimensional
 - Posição Absoluta (Fixa ou Aprendida)
 - Posição Relativa

Token	dim_1	dim_2
O	0.4	-0.8
gato	-0.7	0.6
sentou	0.9	-0.1
no	-0.2	0.7
tapete	0.1	-0.5

+

Pos	dim_1	dim_2
01	0.3	0.2
02	-0.9	-0.6
03	0.0	1.0
04	0.8	-0.3
05	-0.4	0.5

=

Token	dim_1	dim_2
O	0.7	-0.6
gato	-1.6	0.0
sentou	0.9	0.9
no	0.6	0.4
tapete	-0.3	0.0

Recapitulação

- E agregamos a posição de cada token em sua representação multidimensional
 - Posição Absoluta (Fixa ou Apreendida)
 - Posição Relativa
- Dúvidas sobre o material de leitura?
- Por que precisamos considerar a posição dos tokens?

Introdução ao Mecanismo de Atenção

- Desta forma, até o momento temos a representação semântica de cada parte do texto de entrada (token)
- Também, já agregamos a posição de cada token em sua representação semântica
- Qual informação a mais precisamos considerar antes da geração de texto?

Introdução ao Mecanismo de Atenção

- Considere as seguintes frases:

Primeira Frase: The chicken didn't cross the road because **it** was too tired

Segunda Frase: O gato não atravessou o quintal porque **ele** estava muito cansado

- Os pronomes **it** e **ele** apontam para qual palavra antecedente?

Introdução ao Mecanismo de Atenção

- Considere as seguintes frases:

Primeira Frase: The chicken didn't cross the road because **it** was too tired

Segunda Frase: O gato não atravessou o quintal porque **ele** estava muito cansado

- Os pronomes **it** e **ele** apontam para qual palavra antecedente?
- **It** aponta para chicken e **ele** aponta para gato

Introdução ao Mecanismo de Atenção


- Desta forma, **precisamos considerar o contexto entre os tokens**

- Frase original

The girl ran to a local pub to escape the din of her city

A garota correu para um pub local para escapar do tumulto da cidade

- Mas como podemos calcular a relevância entre eles?



Introdução ao Mecanismo de Atenção

- Na arquitetura Transformer, utilizamos o mecanismo de atenção

"A atenção é o mecanismo no transformer que pondera e combina as representações dos outros tokens apropriados no contexto da camada k , para construir a representação dos tokens na camada $k + 1$." (JURAFSKY, 2026)

Para cada token: Mede a relevância dos demais tokens e combina tais informações para a nova representação do token em questão

Simplificação do Mecanismo de Atenção


- Atenção simplificada:

$$\mathbf{a}_i = \sum \alpha_{ij} \mathbf{x}_j$$

$\mathbf{a}_i$ é novo embedding do token i

$\mathbf{x}_j$ é o embedding do token j

α_{ij} é a contribuição de $\mathbf{x}_j$



- Como calcular a contribuição de cada token?

Teste prático: <https://huggingface.co/spaces/exbert-project/exbert>

Simplificação do Mecanismo de Atenção

- A contribuição de cada token pode ser calculada pela similaridade entre ambos
- E a similaridade entre dois tokens pode ser feita através do produto escalar

$$a \cdot b = x_1x_2 + y_1y_2 + z_1z_2$$

- Por fim, normalizamos os produtos escalares através da função softmax

Simplificação do Mecanismo de Atenção

- Atenção simplificada:

$$\mathbf{a}_i = \sum \alpha_{ij} \mathbf{x}_j$$

$$\begin{aligned} \text{score}(\mathbf{x}_i, \mathbf{x}_j) &= \mathbf{x}_i \cdot \mathbf{x}_j \\ \alpha_{ij} &= \text{softmax}(\text{score}(\mathbf{x}_i, \mathbf{x}_j)) \end{aligned}$$

$\mathbf{a}_i$ é novo embedding do token i

$\mathbf{x}_j$ é o embedding do token j

α_{ij} é a contribuição de $\mathbf{x}_j$





Mecanismo de Atenção


- Após esta simplificação, agora podemos entrar nos detalhes do mecanismo de atenção
- Para isso, primeiro começamos com a nossa matriz normalizada
- E para cada token, calculamos três novos vetores:
 - Query Vector (Consulta)
 - Key Vector (Chave)
 - Value Vector (Valor)

Token	dim_1	dim_2
O	1.00	-1.00
gato	...	...
sentou	...	...
no	...	...
tapete	...	...

Mecanismo de Atenção



#Tokens 
#Dimensões

#Dimensões 
#Dimensões /
num_heads

← Aprendida
durante o
treinamento

(HWANG, 2025)

Mecanismo de Atenção

- Cada vetor tem um objetivo único
- Podemos utilizar diferentes analogias para entender a função de cada vetor
- **Analogia da busca na internet**
 - Query Vector** é a frase de busca
 - Key Vector** é o título de cada página retornada
 - Value Vector** é o conteúdo das páginas retornadas
- **A partir dessa analogia, qual o objetivo de cada vetor?**

Mecanismo de Atenção

- Cada vetor tem um objetivo único
- Podemos utilizar diferentes analogias para entender a função de cada vetor
- **Analogia da busca na internet**
 - Query Vector:** Qual informação estou procurando?
 - Key Vector:** Qual informação tenho para oferecer?
 - Value Vector:** Qual conteúdo eu devo transmitir?
- O Vetor Query faz uma pergunta e o Vetor Key responde a pergunta

Mecanismo de Atenção

- **Frase de Exemplo:** O gato não atravessou o quintal porque ele estava muito cansado
- **Exemplo para a substantivo 'gato' e pronome 'ele'**
 - Query Vector:** Pronome 'ele' deve buscar pelo substantivo associado
 - Key Vector:** Substantivo 'gato' deve se apresentado como substantivo
 - Value Vector:** Substantivo 'gato' deve transmitir seu conteúdo semântico

Mecanismo de Atenção

- Exemplo para a substantivo 'gato' e pronome 'ele'

Query Vector: Pronome 'ele' deve buscar pelo substantivo associado

Key Vector: Substantivo 'gato' deve se apresentado como substantivo

Value Vector: Substantivo 'gato' deve transmitir seu conteúdo semântico

- Como podemos medir a similaridade entre a pergunta (query) e a resposta?

Simplificação do Mecanismo de Atenção

- **Relembrando...**


- A contribuição de cada token pode ser calculada pela similaridade entre ambos
- E a similaridade entre dois tokens pode ser feita através do produto escalar

$$a \cdot b = x_1x_2 + y_1y_2 + z_1z_2$$

- Por fim, normalizamos os produtos escalares através da função softmax

Mecanismo de Atenção


- Sendo, assim multiplicamos as matrizes Q (Vetores Query) e K (Vetores Key)



- Porém, alguns valores podem dominar os demais
- Quais técnicas podemos aplicar?

Mecanismo de Atenção


- Sendo, assim multiplicamos as matrizes Q (Vetores Query) e K (Vetores Key)



- Primeiro, aplica-se um escalonamento através da divisão pela raiz da dimensão dos vetores
- Em seguida, normaliza-se cada linha da matriz com a função softmax


Mecanismo de Atenção

- Sendo, assim multiplicamos as matrizes Q (Vetores Query) e K (Vetores Key)



- Porém, desta forma, tokens posteriores influenciam tokens anteriores
- Isto é um problema?


Treinamento de LLMs Causais



(SUBEDI, 2024)

- A frase 'How are you' é dividida em três treinamentos
- Quais são eles?


Treinamento de LLMs Causais



(SUBEDI, 2024)

- Devemos impedir tokens posteriores de influenciar anteriores
- Como podemos fazer isso?

Treinamento de LLMs Causais



(SUBEDI, 2024)

- Uma solução: Definir uma máscara de atenção antes de aplicar a função softmax

Mecanismo de Atenção

- Com a matriz de atenção, calculamos a contribuição dos tokens anteriores em cada token da sequência (incluindo o token em questão)
- Em sequência, a nova representação do token será a soma dos valores dos value vectors, considerando a contribuição de cada um
- Ou seja, multiplicamos a matriz de atenção pela matriz de value vectores

(VASWANI, 2017)

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Simplificação do Mecanismo de Atenção

- **Relembrando...** Atenção simplificada:


$$\mathbf{a}_i = \sum \alpha_{ij} \mathbf{x}_j$$

$$\begin{aligned} \text{score}(\mathbf{x}_i, \mathbf{x}_j) &= \mathbf{x}_i \cdot \mathbf{x}_j \\ \alpha_{ij} &= \text{softmax}(\text{score}(\mathbf{x}_i, \mathbf{x}_j)) \end{aligned}$$

$\mathbf{a}_i$ é novo embedding do token i


$\mathbf{x}_j$ é o embedding do token j

α_{ij} é a contribuição de $\mathbf{x}_j$



Mecanismo de Atenção

- Este processo é aplicado diversas vezes em paralelo (dependendo da configuração de cada modelo)



- Cada aplicação é chamada de cabeça de atenção
- Dúvidas sobre o mecanismo de atenção?

(WIKIDOC, 2023)

Mecanismo de Atenção

- Este processo é aplicado diversas vezes em paralelo (dependendo da configuração de cada modelo)

Diferentes configurações do modelo GPT-2

Variant	Parameters	Layers	Hidden Dimension	Attention Heads	Feed-Forward Dimension	Context Length
Small	124M	12	768	12	3,072	1,024
Medium	355M	24	1,024	16	4,096	1,024
Large	774M	36	1,280	20	5,120	1,024
XL	1.5B	48	1,600	25	6,400	1,024

(AI WIKI, 2026)

Próxima Aula

- Na próxima aula, vamos estudar como conectar os resultados de cada cabeça de atenção
- E como efetivamente gerar novos tokens
- Para próxima aula, ler material complementar do mecanismo de atenção

Self-Attention Explained with Code (SMITH, 2024)

Seções 3.1 - 3.6

Referências

- JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing**: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models. 3. ed. Stanford: Stanford University, 2026.
- VASWANI, Ashish et al. **Attention is all you need**. Advances in neural information processing systems, v. 30, 2017.
- SMITH, Bradney. **Self-Attention Explained with Code**. Towards Data Science, 2024.
- AI WIKI. **GPT-2**. AI Wiki, 2026.

Referências

- WIKIDOC. **Multi-head Attention**. Wikidocs, 2023.
- ARDI, Muhammad. **Meet GPT, The Decoder-Only Transformer**. Towards Data Science, 2025.
- CHO, Aeree et al. **Transformer Explainer**: Interactive Learning of Text-Generative Models. Polo Club of Data Science, Georgia Institute of Technology, 2024.
- NARASIMHA, Srivatsa. **Why is Attention divided by $\sqrt{d_k}$** : The Secret Behind Scaled Attention in Transformers. Medium, 2025.
- SUBEDI, Sanjaya. **Masking in attention**. Sanjaya's Blog, 2024.

Referências

- GHASHAMI, Mina. **Understanding positional embeddings in transformers**: from absolute to rotary. Towards Data Science, 2024.
- BYCROFT, Brendan. **LLM Visualization**. Disponível em: bbycroft.net/llm.
- DESAGULIER, Guillaume. **Word embeddings**: the (very) basics. Around the Word: A Corpus Linguist's Research Notebook, 2018.
- HWANG, Hae-Ji; JEONG, Seon-Geun; HWANG, Won-Joo. **Ultrawideband non-line-of-sight classification using transformer-convolutional neural networks**. IEEE Access, 2025.
- BRENNDOERFER, Michael. **Query, Key, Value: The Foundation of Transformer Attention**, 2025.

Aula 3

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 17 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA

LABICOM
Laboratório de Pesquisa
em Inteligência Computacional