

Aula 4

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 22 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA

LABICOM
Laboratório de Pesquisa
em Inteligência Computacional

Aula de Hoje

- Na última aula, estudamos o mecanismo de atenção
- Além disso, foi encaminhado um material complementar para leitura

Self-Attention Explained with Code (SMITH, 2024)

Seções 3.1 - 3.6


- Quais os três pontos principais do material?

Aula de Hoje

- Revisão do mecanismo de atenção
- Atenção multicabeça
- Rede neural feed-forward
- E como efetivamente gerar novos tokens (próxima aula)

Arquitetura GPT-2

Dúvidas sobre as etapas do modelo de linguagem?




Revisão do Mecanismo de Atenção

- Até o momento temos a representação semântica de cada parte do texto de entrada (token)
- E cada representação foi agregada com a posição de cada token
- Qual informação a mais precisamos considerar antes da geração de texto?

Revisão do Mecanismo de Atenção

- Desta forma, **precisamos considerar o contexto entre os tokens**




(SMITH, 2024)

- **Bank**

- Instituição Financeira
- Margem do rio


Simplificação do Mecanismo de Atenção



(SMITH, 2024)

- Frase: *Write a poem about a man fishing on a river bank*
- Primeiro Passo: Calcular similaridade entre os tokens


Simplificação do Mecanismo de Atenção



(SMITH, 2024)

- Segundo passo: Escalar e normalizar as similaridades

Simplificação do Mecanismo de Atenção



(SMITH, 2024)

- Terceiro passo: Atualizar a representação do token pela soma ponderada dos demais

Simplificação do Mecanismo de Atenção

- Atenção simplificada:

$$\mathbf{a}_i = \sum \alpha_{ij} \mathbf{x}_j$$

$\mathbf{a}_i$ é novo embedding do token i

$\mathbf{x}_j$ é o embedding do token j

α_{ij} é a contribuição de $\mathbf{x}_j$



Simplificação do Mecanismo de Atenção

Calculate the Weighted Sum


Multiply each embedding by the weights to find the fraction of each vector to add to form the new embedding.

$$\sum_{i=0}^{L_{max}} W_{bank_i} \cdot X_i = \begin{aligned} & W_{write} \left\{ \begin{matrix} 0.00 \end{matrix} \right\} \times \begin{bmatrix} 4.62 & 0.92 & \dots & 0.93 \end{bmatrix} \left. \vphantom{\begin{matrix} 0.00 \end{matrix}} \right\} X_{write} \\ & + W_a \left\{ \begin{matrix} 0.00 \end{matrix} \right\} \times \begin{bmatrix} 0.35 & 2.57 & \dots & 2.43 \end{bmatrix} \left. \vphantom{\begin{matrix} 0.00 \end{matrix}} \right\} X_a \\ & + W_{poem} \left\{ \begin{matrix} 0.02 \end{matrix} \right\} \times \begin{bmatrix} 2.04 & 1.49 & \dots & 1.20 \end{bmatrix} \left. \vphantom{\begin{matrix} 0.02 \end{matrix}} \right\} X_{poem} \\ & \dots \\ & + W_{bank} \left\{ \begin{matrix} 0.63 \end{matrix} \right\} \times \begin{bmatrix} 0.14 & 5.46 & \dots & 0.32 \end{bmatrix} \left. \vphantom{\begin{matrix} 0.63 \end{matrix}} \right\} X_{bank} \\ & = \begin{bmatrix} 0.15 & 5.62 & \dots & 0.34 \end{bmatrix} \\ & \quad \quad \quad y_{bank} \\ & \quad \quad \quad (1 \times d_{model}) \\ & \quad \quad \quad \text{Transformer embedding for "bank"} \end{aligned}$$

(SMITH, 2024)

Atenção Multicabeça

- Este processo é aplicado diversas vezes em paralelo (dependendo da configuração de cada modelo)



- Cada aplicação é chamada de cabeça de atenção
- Por que utilizar múltiplas cabeças de atenção?


(WIKIDOC, 2023)

Atenção Multicabeça

- Por que utilizar múltiplas cabeças de atenção?
- Cada cabeça de atenção pode atender o contexto de uma forma diferente
 - Especialização em diferentes relações linguísticas
 - Encontrar padrões específicos dentro do contexto

Atenção Multicabeça




- Tipos de relações encontradas por uma cabeça de atenção
 - Relação Semântica
 - Relação Gramatical



(MEHRA, 2025)

- Como conectar o resultado de cada mecanismo de atenção?

Atenção Multicabeça



(HWANG, 2025)




Atenção Multicabeça

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(VASWANI, 2017)

- Quais são as dimensões da saída de cada cabeça de atenção?
- **Dica:** O escalonamento e a normalização não alteram a dimensão das matrizes


Atenção Multicabeça




- Qual o resultado da multiplicação das duas matrizes?


(HWANG, 2025)

Atenção Multicabeça



(HWANG, 2025)

#Tokens (T) 
#Dimensões /
num_heads (A)

#Tokens (T) 
#Dimensões /
num_heads (A)

#Tokens (T) 
#Dimensões /
num_heads (A)

Atenção Multicabeça

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

(VASWANI, 2017)


Matriz Q (T x A)

Matriz K (T x A)


Matriz V (T x A)

- A multiplicação da matriz Q por K transposta gera a matriz de atenção
- Que posteriormente é escalonada e normalizada
- Qual a dimensão da matriz final?

(NARASIMHA, 2025)



Atenção Multicabeça



(MEHRA, 2025)

- Cada cabeça de atenção gera uma matriz com T linhas e A colunas

- Relembrando

T = Tokens de entrada

$A = \frac{\text{\#Dimensões}}{\text{num_heads}}$ (A)

└─ Tamanho do vetor multidimensional
que cada token é transformado

- Por que não utilizar cabeças de atenção do tamanho dos embeddings iniciais?

Atenção Multicabeça


- Os resultados são empilhados e formam uma nova matriz com T tokens e D dimensões

Token	dim_1	dim_2	dim_3	dim_4	dim_5	dim_6
O	0.4	-0.6	0.4	0.3	-0.3	0.1
gato	-0.7	0.3	-0.8	0.1	0.2	-0.4
sentou	-0.9	0.1	0.6	0.7	-0.8	-0.6
no	-0.0	-0.5	0.4	-0.6	0.5	0.2
tapete	0.3	0.9	-0.8	-0.1	0.8	-0.3

└─ Resultado da primeira
cabeça de atenção

Atenção Multicabeça


- Por fim, para conectar os resultados de cada cabeça de atenção, aplica-se uma projeção



(BYCROFT, 2023)

Arquitetura GPT-2

Qual processo é feito depois da aplicação da camada de atenção?



Atenção Multicabeça

- O resultado da camada de atenção é somado com a entrada inicial
- Quais os benefícios deste processo?

Token	dim_1	dim_2
O	0.4	-0.8
gato	-0.7	0.6
sentou	0.9	-0.1
no	-0.2	0.7
tapete	0.1	-0.5

Input embedding matrix


+

Token	dim_1	dim_2
O	0.3	0.2
gato	-0.9	-0.6
sentou	0.0	1.0
no	0.8	-0.3
tapete	-0.4	0.5

Attention output matrix

Atenção Multicabeça


- O resultado da camada de atenção é somado com a entrada inicial
- Quais os benefícios deste processo?
- Melhor fluxo de gradientes e maior velocidade de treinamento
- Contribui para a robustez e a regularização do modelo



(SMITH, 2024)

Arquitetura GPT-2

Próxima camada:
Rede neural feed-forward




Rede Neural Feed-Forward

- A camada de atenção tem o objetivo de compreender a relação entre os tokens
- Qual seria o objetivo da rede neural feed-forward?
 - Os tokens já são representados em vetores multidimensionais
 - A relação entre eles já foi calculada
- **Dica:** Todos os tokens são processados pela mesma rede de forma independente

Rede Neural Feed-Forward


- A camada de atenção tem o objetivo de compreender a relação entre os tokens
- Qual seria o objetivo da rede neural feed-forward?
 - Refinar a representação individual de cada token
 - Os parâmetros da rede neural são aprendidos durante o treinamento
 - Portanto, a rede conecta o conhecimento aprendido com a representação de cada token



- A rede neural armazena diversos padrões para refinar a representação dos tokens
- As camadas iniciais contêm padrões mais rasos
- As camadas finais contêm padrões mais semânticos

(WASOWSKI, 2026)

Rede Neural Feed-Forward




- Quais camadas devem ser atualizadas em um processo de fine-tuning?

↳ Ajuste do modelo para conjunto específico de dados

(WASOWSKI, 2026)

Rede Neural Feed-Forward




- Quais camadas devem ser atualizadas em um processo de fine-tuning?

↳ Ajuste do modelo para conjunto específico de dados

- Camadas finais que contêm padrões mais semânticos

(WASOWSKI, 2026)

Rede Neural Feed-Forward



(WASOWSKI, 2026)

- Os padrões são primeiro identificados
- As correspondências fracas são suprimidas
- Os tokens são atualizados a partir dos valores correspondentes

Rede Neural Feed-Forward

- Além disso, ressalta-se que as matrizes de entrada e saída da rede neural possuem o mesmo tamanho

Token	dim_1	dim_2
O	0.4	-0.8
gato	-0.7	0.6
sentou	0.9	-0.1
no	-0.2	0.7
tapete	0.1	-0.5

Entrada da rede



Token	dim_1	dim_2
O	0.3	0.2
gato	-0.9	-0.6
sentou	0.0	1.0
no	0.8	-0.3
tapete	-0.4	0.5


Saída da rede

Arquitetura GPT-2

Camada de atenção:
Raciocínio contextual

Rede Neural Feed-Forward:
Conhecimento do treinamento

Visualização: <https://poloclub.github.io/transformer-explainer/>



Próxima Aula

- Dúvidas sobre o conteúdo de hoje?
- Na próxima aula, vamos estudar como efetivamente gerar novos tokens
- Para próxima aula, ler material complementar sobre as redes neurais feed-forward nos modelos de linguagem

Feed-Forward Networks in LLMs (SHEKHAR, 2026)

Referências

- JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models.** 3. ed. Stanford: Stanford University, 2026.
- VASWANI, Ashish et al. **Attention is all you need.** Advances in neural information processing systems, v. 30, 2017.
- SMITH, Bradney. **Self-Attention Explained with Code.** Towards Data Science, 2024.
- SHEKHAR, Amit. **Feed Forward Networks in LLMs.** Outcome School, 2026.

Referências

- WIKIDOC. **Multi-head Attention**. Wikidocs, 2023.
- ARDI, Muhammad. **Meet GPT, The Decoder-Only Transformer**. Towards Data Science, 2025.
- CHO, Aeree et al. **Transformer Explainer**: Interactive Learning of Text-Generative Models. Polo Club of Data Science, Georgia Institute of Technology, 2024.
- WASOWSKI, Jaroslaw. **Feed-Forward Networks in Transformers — LLM Knowledge Store**. Medium, 2026.
- MEHRA, Vaibhav. **Understanding Multi-Head Attention in Transformers**. DataCamp, 2025.

Referências

- BYCROFT, Brendan. **LLM Visualization**. Disponível em: bbycroft.net/llm.
- HWANG, Hae-Ji; JEONG, Seon-Geun; HWANG, Won-Joo. **Ultrawideband non-line-of-sight classification using transformer-convolutional neural networks**. IEEE Access, 2025.
- SHEKHAR, Amit. **Decoding Transformer Architecture**. Outcome School, 2026.

Aula 4

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 22 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA

LABICOM
Laboratório de Pesquisa
em Inteligência Computacional