

Aula 5

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 24 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA


LABICOM
Laboratório de Pesquisa
em Inteligência Computacional

Aula de Hoje

- Empilhamento de bloco decoder
- Predição de texto (Último componente da arquitetura)
- Visão geral dos componentes principais da arquitetura
 - Tokenização
 - Embeddings
 - Atenção
 - Rede neural feed-forward
 - Geração de texto


Arquitetura GPT-2

Dúvidas sobre as etapas do modelo de linguagem?



Recapitulação


- O nosso objetivo é construir um modelo generativo, ou seja, que gere texto novo
- No caso dos chatbots, queremos uma conversa entre sistema e usuário
- Ou seja, iniciamos com um texto de entrada e desejamos um texto de saída (com base na entrada)



Arquitetura GPT-2


O bloco decoder é composto pela atenção e a rede feed-forward

Por que o bloco é repetido N vezes?



Empilhamento de blocos decoder

- Por que o bloco decoder é repetido N vezes?
 - Possibilita capturar padrões mais complexos




- Como essa complexidade é dividida entre os blocos?

(WOLFE, 2024)

Empilhamento de blocos decoder

- Como essa complexidade é dividida entre os blocos?
- Processamento hierárquico!
 - Blocos iniciais podem focar em padrões mais superficiais
 - Blocos subsequentes podem focar em relações mais abstratas e conhecimento factual

Rede Neural Feed-Forward



- Cada rede feed-forward armazena diversos padrões para refinar a representação dos tokens
- As redes iniciais contêm padrões mais rasos
- As redes finais contêm padrões mais semânticos

(WASOWSKI, 2026)

Empilhamento de blocos decoder

- Depois de passarem por múltiplos blocos decoder, os tokens deixam de representar seu significado inicial
 - Foram alterados pelo contexto e pelo conhecimento do treinamento
 - Com o objetivo de serem úteis para prever o próximo token

Geração do token de saída

- Como utilizar a última representação dos tokens para gerar o token seguinte?

Token	dim_1	dim_2	dim_3
O	0.3	0.2	0.4
gato	-0.9	-0.6	-0.8
sentou	0.0	1.0	0.6
no	0.8	-0.3	0.4

Saída do último bloco decoder

Frase de entrada: O gato
sentou no ...

- Dica: Todos os tokens do vocabulário podem ser preditos


Geração do token de saída

- Podemos transformar a matriz final em uma lista de probabilidades para cada token do vocabulário

Token	dim_1	dim_2	dim_3
O	0.3	0.2	0.4
gato	-0.9	-0.6	-0.8
sentou	0.0	1.0	0.6
no	0.8	-0.3	0.4
???	...	...	...

Frase de entrada: O gato
sentou no ...

Treinamento de LLMs Causais



(SUBEDI, 2024)

- Porém, para o treinamento ser eficiente, faz sentido fazer a previsão do token seguinte para todos os tokens da frase
- Frase inicial: How are you

Geração do token de saída

- Portanto, precisamos transformar cada token em uma lista de probabilidades

Token	dim_1	dim_2	dim_3
O	0.3	0.2	0.4
gato	-0.9	-0.6	-0.8
sentou	0.0	1.0	0.6
no	0.8	-0.3	0.4



Token	gato	tapete	casa	...
O	5.00%	3.00%	0.01%	...
gato	0.01%	0.01%	0.01%	...
sentou	0.01%	0.01%	0.01%	...
no	1.00%	4.00%	0.00%	...

Frase de entrada: O gato
sentou no ...

- Como podemos fazer isso?

Geração do token de saída

- Uma possibilidade é multiplicar a matriz por outra aprendida durante o treinamento

Token	dim_1	dim_2	dim_3
O	0.3	0.2	0.4
gato	-0.9	-0.6	-0.8
sentou	0.0	1.0	0.6
no	0.8	-0.3	0.4



Token	gato	tapete	casa	...
O	5.00%	3.00%	0.01%	...
gato	0.01%	0.01%	0.01%	...
sentou	0.01%	0.01%	0.01%	...
no	1.00%	4.00%	0.00%	...

Frase de entrada: O gato
sentou no ...

- Quais as dimensões de cada uma das matrizes?

Geração do token de saída

- Uma possibilidade é multiplicar a matriz por outra aprendida durante o treinamento

Token	dim_1	dim_2	dim_3
O	0.3	0.2	0.4
gato	-0.9	-0.6	-0.8
sentou	0.0	1.0	0.6
no	0.8	-0.3	0.4

Tokens (T) x Embeddings (C)



Token	gato	tapete	casa	...
O	5.00%	3.00%	0.01%	...
gato	0.01%	0.01%	0.01%	...
sentou	0.01%	0.01%	0.01%	...
no	1.00%	4.00%	0.00%	...

Tokens (T) x n_vocab

- E precisamos multiplicar a saída do último bloco decoder por uma matriz de tamanho $C \times n_vocab$

Geração do token de saída

- Porém, a multiplicação pode gerar valores diversos (positivos e negativos)

- Como transformar os valores em probabilidades?

- Frase: O gato sentou no ...

- Logits:

gato => 2.0

tapete => 8.1

casa => 1.0



- Probabilidades:

gato => 0.2%

tapete => 99.7%

casa => 0.1%

Geração do token de saída

- Como transformar os valores em probabilidades?
- Podemos utilizar novamente a função softmax (aplicada em cada linha)

Token	gato	tapete	casa	...
O	5.00%	3.00%	0.01%	...
gato	0.01%	0.01%	0.01%	...
sentou	0.01%	0.01%	0.01%	...
no	1.00%	4.00%	0.00%	...


Tokens (T) x n_vocab

- Para inferência, precisamos utilizar todas as linhas?

Geração do token de saída

- No treinamento, utiliza-se todas as linhas para ajuste dos pesos para garantir eficiência
 - 1 forward pass
 - 1 cálculo de loss (média dos erros)
 - 1 backpropagation (ajusta todos os pesos de uma vez)
- Quantas predições simultâneas para uma frase com N tokens?
- Qual a predição do último token?

Treinamento de LLMs Causais



(SUBEDI, 2024)

- Durante o treinamento, N previsões são feitas para uma frase com N tokens (A última previsão é para o token <EOS>)

Geração do token de saída

- Para a inferência, utilizamos apenas as probabilidades do último token

Token	gato	tapete	casa	...
O	5.00%	3.00%	0.01%	...
gato	0.01%	0.01%	0.01%	...
sentou	0.01%	0.01%	0.01%	...
no	1.00%	4.00%	0.00%	...

Tokens (T) x n_vocab

- Frase: O gato sentou no ...
- Predição: tapete
- Como continuar a geração de texto?

Geração do token de saída

- Estes modelos são chamados de autorregressivos, ou seja, fazem a geração de texto de forma sequencial

Primeira Iteração:

Entrada: Qual é a capital da França?

Saída: A

Segunda Iteração:

Entrada: Qual é a capital da França? A

Saída: capital

...

Seleção do token de saída

- Quais estratégias podemos utilizar para selecionar os tokens de saída?

- Frase: O gato sentou no ...

- Logits:

gato => 2.0

tapete => 8.1

casa => 1.0



- Probabilidades:


gato => 0.2%

tapete => 99.7%

casa => 0.1%

Seleção do token de saída

- Primeira estratégia: Escolher o token seguindo as probabilidades (Random sampling)




(JURAFSKY, 2026)

- Quais são as vantagens e desvantagens deste método?

Seleção do token de saída

- Primeira estratégia: Escolher o token seguindo as probabilidades (Random sampling)




(JURAFSKY, 2026)

- Geração de texto dinâmico (criatividade)
- Ainda há probabilidade de gerar tokens muito pouco prováveis

Seleção do token de saída

- Segunda estratégia: Escolher sempre o token com maior probabilidade (Greedy Decoding)




(JURAFSKY, 2026)

- Quais são as vantagens e desvantagens deste método?

Seleção do token de saída

- Segunda estratégia: Escolher sempre o token com maior probabilidade (Greedy Decoding)




(JURAFSKY, 2026)

- Geração pouco criativa
- Para quais tarefas esta é a melhor escolha?

Seleção do token de saída

- Terceira estratégia: Alterar a distribuição de probabilidades antes de selecionar o próximo token (Temperature sampling)




(JURAFSKY, 2026)

- Qual o impacto da variável temperatura?
- Quais são as vantagens e desvantagens deste método?

Seleção do token de saída

- Terceira estratégia: Alterar a distribuição de probabilidades antes de selecionar o próximo token (Temperature sampling)



(GEEKFORGEEKS, 2026)

- Qual o impacto da variável temperatura?
- Quais são as vantagens e desvantagens deste método?

Seleção do token de saída

- Estratégias mais utilizadas: Top-k
 - Mantém apenas os k tokens mais prováveis
 - Define a probabilidade dos demais para zero
- Posso utilizar o conceito de temperatura em conjunto?
Faz sentido?
- Quais são as vantagens e desvantagens deste método?


Seleção do token de saída

- Estratégias mais utilizadas: Top-p
 - Mantém apenas os tokens mais prováveis, de tal forma que a soma de suas probabilidades seja pelo menos p
 - Normaliza a probabilidade dos tokens selecionados ($\text{prob} / \text{soma}$)
- Posso utilizar o conceito de temperatura em conjunto? Faz sentido?
- Quais são as vantagens e desvantagens deste método?

Arquitetura GPT-2

Dúvidas sobre a geração de texto?

Agora vamos recapitular as principais etapas



Recapitulação Tokenização

- Separamos o texto de entrada em partes menores, chamadas de tokens

A rápida raposa marrom pula
sobre o cachorro preguiçoso




A rápida raposa marrom pula sobre
o cachorro preguiçoso

- Por que separar o texto em partes menores?
- Por que em tokens?

Recapitulação Embeddings

- Transformamos cada token em um vetor multidimensional




- Por que converter em vetores multidimensionais?

(DESAGULIER, 2018)

Revisão do Mecanismo de Atenção

- Consideramos o contexto entre os tokens




(SMITH, 2024)

- **Bank**

- Instituição Financeira
- Margem do rio

Revisão Rede Neural Feed-Forward




(WASOWSKI, 2026)

- Refinamos a representação individual de cada token
- Dúvidas sobre o material complementar sobre as redes neurais nos LLMs?

Revisão Seleção do token de saída

- E por fim, geramos texto novo de forma autoregressiva (token por token)




(JURAFSKY, 2026)

Arquitetura GPT-2

Dúvidas sobre as etapas do modelo de linguagem?

Obrigado pela atenção!



Referências

- JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models.** 3. ed. Stanford: Stanford University, 2026.
- VASWANI, Ashish et al. **Attention is all you need.** Advances in neural information processing systems, v. 30, 2017.
- SMITH, Bradney. **Self-Attention Explained with Code.** Towards Data Science, 2024.
- SHEKHAR, Amit. **Feed Forward Networks in LLMs.** Outcome School, 2026.

Referências

- GEEKSFORGEEKS. **Temperature, Top-K and Top-P Sampling in LLMs**. Geeksforgeeks, 2026.
- ARDI, Muhammad. **Meet GPT, The Decoder-Only Transformer**. Towards Data Science, 2025.
- CHO, Aeree et al. **Transformer Explainer**: Interactive Learning of Text-Generative Models. Polo Club of Data Science, Georgia Institute of Technology, 2024.
- WASOWSKI, Jaroslaw. **Feed-Forward Networks in Transformers — LLM Knowledge Store**. Medium, 2026.
- MEHRA, Vaibhav. **Understanding Multi-Head Attention in Transformers**. DataCamp, 2025.

Referências

- BYCROFT, Brendan. **LLM Visualization**. Disponível em: bbycroft.net/llm.
- APXML. **Stacking multiple encoder/decoder layers**. Foundations of Transformers Architecture, 2026.
- WOLFE, Cameron R. **Decoder-Only Transformers**: The Workhorse of Generative LLMs. Deep (Learning) Focus, 2024.
- SUBEDI, Sanjaya. **Masking in attention**. Sanjaya's Blog, 2024.
- DESAGULIER, Guillaume. **Word embeddings**: the (very) basics. Around the Word: A Corpus Linguist's Research Notebook, 2018.

Aula 5

Grandes Modelos de Linguagem

Gabriel Lenz Balatka

Orientador: Rafael Stubs Parpinelli

Joinville, 24 de junho de 2026



UDESC
UNIVERSIDADE
DO ESTADO DE
SANTA CATARINA

LABICOM
Laboratório de Pesquisa
em Inteligência Computacional